

# Laporan Tugas Praproses Data

## Dataset House Prices

Raihan Nurhakim - 5054251030

### 1. Deskripsi Dataset

Dataset yang digunakan adalah dataset House Prices yang terdiri dari 1.460 data dan 81 atribut (termasuk kolom Id). Dataset ini mencakup berbagai informasi mengenai karakteristik rumah, mulai dari luas tanah, kualitas bangunan, tahun pembangunan, hingga fasilitas. Dengan *SalePrice* sebagai target variabel.


| Informasi         | Nilai |
|-------------------|-------|
| Jumlah baris      | 1.460 |
| Jumlah kolom awal | 81    |
| kolom numerik     | 38    |
| kolom kategoris   | 43    |

Tabel 1. Informasi umum dataset.

### 2. Pembersihan Data

#### 2.1. Deteksi Data Hilang

Pemeriksaan nilai hilang dilakukan menggunakan *df.isnull().sum()*. Ditemukan 19 kolom memiliki nilai hilang, dengan variasi proporsi dari <1% hingga 99.5%.



*Gambar 1. Presentase nilai hilang per kolom.*

## 2.2. Penanganan Nilai Hilang

Penanganan missing values dilakukan berdasarkan proporsi nilai yang hilang pada setiap atribut. Kolom dengan persentase nilai hilang lebih dari 50% dihapus karena dianggap tidak memberikan informasi yang memadai untuk pemodelan. Berdasarkan kriteria tersebut, terdapat lima kolom yang dihapus, yaitu *PoolQC*, *MiscFeature*, *Alley*, *Fence*, dan *MasVnrType*.

Selanjutnya, untuk kolom numerik yang tersisa, imputasi dilakukan menggunakan nilai median karena lebih tahan (*robust*) terhadap *outliers*. Sementara itu, kolom kategoris diimputasi menggunakan nilai modus. Setelah tahap pembersihan data ini selesai, dataset memiliki 76 kolom tanpa ada nilai hilang (0 missing values).

| Kolom        | Jumlah Hilang | Proporsi | Keterangan      |
|--------------|---------------|----------|-----------------|
| PoolQC       | 1.453         | 99.5%    | dihapus         |
| MiscFeature  | 1.406         | 96.3%    | dihapus         |
| Alley        | 1.369         | 93.8%    | dihapus         |
| Fence        | 1.179         | 80.8%    | dihapus         |
| MasVnrType   | 872           | 59.7%    | dihapus         |
| FireplaceQu  | 690           | 47.3%    | imputasi modus  |
| LotFrontage  | 259           | 17.7%    | imputasi median |
| GarageType   | 81            | 5.5%     | imputasi modus  |
| GarageYrBlt  | 81            | 5.5%     | imputasi median |
| GarageFinish | 81            | 5.5%     | imputasi modus  |
| GarageQual   | 81            | 5.5%     | imputasi modus  |
| GarageCond   | 81            | 5.5%     | imputasi modus  |
| BsmtExposure | 38            | 2.6%     | imputasi modus  |
| BsmtFinType2 | 38            | 2.6%     | imputasi modus  |
| BsmtQual     | 37            | 2.5%     | imputasi modus  |
| BsmtCond     | 37            | 2.5%     | imputasi modus  |

|              |    |      |                 |
|--------------|----|------|-----------------|
| BsmtFinType1 | 37 | 2.5% | imputasi modus  |
| MasVnrArea   | 8  | 0.5% | imputasi median |
| Electrical   | 1  | 0.1% | imputasi modus  |

Tabel 2. Informasi penanganan nilai hilang tiap kolom.

### 3. Deteksi dan Penanganan Outlier


Deteksi *outliers* dilakukan pada seluruh atribut numerik menggunakan metode *Interquartile Range* (IQR). Observasi dengan nilai yang berada di bawah batas bawah ( $Q1 - 1,5 \times IQR$ ) atau di atas batas atas ( $Q3 + 1,5 \times IQR$ ) diidentifikasi sebagai nilai ekstrem. Hasil identifikasi menunjukkan beberapa variabel memiliki outliers dalam jumlah yang bervariasi, seperti yang disajikan pada tabel berikut.

| Kolom         | Jumlah Outlier |
|---------------|----------------|
| EnclosedPorch | 208            |
| BsmtFinSF2    | 167            |
| OverallCond   | 125            |
| ScreenPorch   | 116            |
| LotFrontage   | 106            |
| MSSubClass    | 103            |
| MasVnrArea    | 98             |
| BsmtHalfBath  | 82             |
| OpenPorchSF   | 77             |
| LotArea       | 69             |


Tabel 3. Informasi jumlah outlier tiap kolom.

Untuk menangani nilai ekstrem tersebut, strategi yang digunakan adalah *capping* (*winsorizing*), yaitu menyesuaikan nilai *outlier* ke batas IQR terdekat (nilai batas bawah atau batas atas) tanpa menghapus baris data. Pendekatan ini dipilih agar jumlah dataset tetap utuh sebanyak 1.460 baris dan mencegah hilangnya data valid, seperti transaksi rumah mewah dengan nilai yang sangat tinggi. Efektivitas penyesuaian distribusi data sebelum dan sesudah digunakannya metode *capping* dapat dilihat melalui visualisasi boxplot pada gambar berikut.

**Boxplot (Sebelum Capping)**



*Gambar 2. Sampel boxplot sebelum capping.*



Gambar 3. Sampel boxplot setelah capping.

#### 4. Transformasi Data

##### 4.1. One-Hot Encoding

Seluruh atribut kategoris dikonversi ke bentuk numerik menggunakan metode *One-Hot Encoding* agar dapat diproses pada tahap analisis data dan reduksi dimensi. Untuk menghindari *multikolinearitas*, parameter *drop\_first=True* diterapkan selama proses transformasi. Karena setiap nilai kategori direpresentasikan sebagai variabel biner baru, jumlah fitur mengalami peningkatan dari 76 kolom menjadi 233 kolom. Proses transformasi ini menghasilkan dimensi dataset baru berukuran 1.460 baris dan 233 kolom.

```
... Shape setelah One-Hot Encoding: (1460, 233)
```

Gambar 4. Ukuran dataset setelah One-Hot Encoding.

##### 4.2. Standarisasi

Tahap selanjutnya setelah *encoding* adalah standarisasi seluruh atribut numerik menggunakan *StandardScaler* berbasis *Z-score*.

StandardScaler dipilih untuk menyetarakan skala antarfitur menggunakan transformasi Z-score, sehingga fitur dengan rentang nilai yang berbeda dapat digunakan secara sebanding dalam proses PCA. Penanganan outlier telah dilakukan sebelumnya menggunakan metode capping berbasis IQR. Transformasi ini berhasil mengubah distribusi data sehingga memiliki rata-rata sebesar 0,0 dan standar deviasi rata-rata sekitar 0,96, memastikan seluruh variabel berada pada rentang skala yang sebanding.

```
... Mean rata-rata fitur (seharusnya ~0): 0.0
    Std rata-rata fitur (seharusnya ~1): 0.9617
```

Gambar 5. Hasil standarisasi menggunakan StandardScaler.

## 5. Reduksi Dimensi

### 5.1. Analisis Korelasi


Tahap selanjutnya adalah analisis korelasi antarfitur yang dilakukan untuk mengidentifikasi variabel-variabel dengan tingkat kemiripan informasi yang tinggi. Dengan menghitung matriks korelasi absolut, diterapkan ambang batas korelasi sebesar  $> 0,95$  untuk mengeliminasi fitur-fitur yang redundan. Dari hasil seleksi ini, sebanyak 5 fitur dihapus, yaitu *Exterior2nd\_CBlock*, *Exterior2nd\_CmentBd*, *Exterior2nd\_MetalSd*, *Exterior2nd\_VinylSd*, dan *SaleCondition\_Partial*. Proses ini mengurangi fitur yang memiliki informasi sangat redundant sehingga jumlah fitur berkurang dari 233 menjadi 228 fitur.

```
... Kolom dihapus (korelasi > 0.95): 5
    ['Exterior2nd_CBlock', 'Exterior2nd_CmentBd', 'Exterior2nd_MetalSd', 'Exterior2nd_VinylSd', 'SaleCondition_Partial']
    Shape setelah seleksi korelasi: (1460, 228)
```

Gambar 6. Hasil seleksi fitur berdasarkan korelasi.

### 5.2. Principal Component Analysis (PCA)

Tahap akhir pra-pemrosesan data dilakukan dengan menerapkan metode *Principal Component Analysis* (PCA) untuk reduksi dimensi lanjutan. Teknik ini digunakan untuk menyederhanakan struktur fitur dengan tetap mempertahankan variansi informasi data sebesar 95%. Hasil pemrosesan menunjukkan bahwa dari 228 fitur numerik yang diinputkan, PCA mampu mengekstrak 150 komponen utama yang memenuhi target kumulatif variansi tersebut. Dengan demikian, dimensi dataset berhasil disederhanakan dari 228 fitur menjadi 150 komponen PCA tanpa mengubah jumlah total observasi, yaitu 1.460 baris data.



Gambar 7. Cumulative explained variance PCA.

#### 6. Ringkasan Hasil Preprocessing

Secara keseluruhan, tahapan preprocessing menghasilkan perubahan dimensi dataset sebagai berikut.

| Tahap Praproses          | Ukuran Dataset |
|--------------------------|----------------|
| Dataset Awal             | 1.460 x 81     |
| Hapus Kolom >50% Missing | 1.460 x 76     |
| Imputasi Nilai Hilang    | 1.460 x 76     |
| Capping Outlier (IQR)    | 1.460 x 76     |
| One-Hot Encoding         | 1.460 x 233    |
| Standarisasi Z-score     | 1.460 x 233    |
| Hapus Korelasi >0.95     | 1.460 x 228    |
| PCA (95% variance)       | 1.460 x 150    |

Tabel 4. Ringkasan perubahan ukuran dataset pada setiap tahap preprocessing.

Setelah melalui rangkaian tahapan preprocessing, mulai dari penanganan *missing values*, *capping outlier* berbasis IQR, *encoding* kategoris One-Hot Encoding, standarisasi Z-score, hingga pengeliminasian fitur redundan

berkorelasi  $> 0,95$ . Dataset akhir kini berada dalam kondisi bersih dan siap untuk tahap pemodelan. Metode *Principal Component Analysis* (PCA) berhasil mereduksi 228 fitur hasil preprocessing menjadi 150 komponen utama dengan mempertahankan 95% variansi data. Terdiri dari 1.460 observasi, 150 fitur PCA dan tanpa *missing value*, sementara *outlier* pada atribut numerik telah ditangani menggunakan metode *capping* berbasis IQR.