

Laporan Tugas Scraping dan EDA

Dataset Perguruan Tinggi Amerika Serikat

Raihan Nurhakim – 5054251030

1. Deskripsi Dataset

Dataset ini berisi informasi mengenai 1.682 perguruan tinggi di 33 negara bagian Amerika Serikat yang diperoleh melalui proses web scraping. Dataset mencakup tujuh atribut utama, yaitu School (nama institusi), Location (kota), Control (jenis kepemilikan, Public/Private/Other), Type (klasifikasi institusi), Enrollment (jumlah mahasiswa terdaftar), Founded (tahun berdiri), dan State (negara bagian).

2. Statistik Deskriptif

2.1. Atribut Numerik

Tabel berikut merangkum statistik deskriptif untuk dua variabel numerik utama:

Atribut	Min	Maks	Rata-rata	Median
Enrollment	6	210.208	5.495	2.174
Founded (Tahun)	1636	2024	1920	~1920

Enrollment memiliki distribusi yang sangat right-skewed: median (2.147) jauh lebih kecil dari rata-rata (5.495), menandakan adanya institusi berukuran sangat besar yang menarik rata-rata ke atas. Perguruan tertua berdiri tahun 1636 (Harvard University), sedangkan yang terbaru didirikan pada 2024.

2.2. Atribut Kategorikal

Berdasarkan jenis kepemilikan (Control), distribusinya adalah: Private 884 institusi (52,6%), Public 614 (36,5%), dan Other 184 (10,9%). Secara geografis, Pennsylvania merupakan negara bagian dengan jumlah institusi terbanyak (± 185), diikuti oleh Virginia, Ohio, dan Illinois.

3. Penanganan Data

3.1. Missing Values

Pada dataset mentah (colleges_raw.csv) ditemukan nilai hilang pada beberapa kolom:

Kolom	Jumlah Missing	Persentase
Founded	219	13,0%
Control	148	8,8%
Enrollment	48	2,9%
Type	37	2,2%
Location	18	1,1%


Penanganan dilakukan dengan mengisi nilai median yang memiliki nilai hilang pada kolom-kolom kritis (Enrollment dan Founded) karena kedua kolom tersebut digunakan dalam analisis kuantitatif. Baris dengan missing pada Control, Type, dan Location dilabeli sebagai kategori "Unknown".

3.2.Outlier

Variabel Enrollment menunjukkan outlier ekstrem yang terlihat pada boxplot (lihat Gambar 4). Institusi seperti universitas negeri besar memiliki lebih dari 200.000 mahasiswa. Outlier ini tidak dihapus karena merupakan data valid (universitas besar memang ada), namun sumbu logaritmik digunakan dalam visualisasi untuk menangani rentang nilai yang sangat lebar ini.

4. Visualisasi & Interpretasi


Gambar 1: Distribusi Institusi berdasarkan Control dan Negara Bagian



Gambar 1. Kiri: Jumlah institusi per jenis kepemilikan. Kanan: 15 negara bagian dengan institusi terbanyak.

Insight: Institusi swasta (Private) mendominasi dengan 884 institusi, hampir $1,5\times$ lebih banyak dari institusi publik (614). Hal ini mencerminkan ekosistem pendidikan tinggi AS yang sangat bergantung pada sektor swasta. Pennsylvania menjadi negara bagian dengan konsentrasi perguruan tinggi tertinggi, kemungkinan karena kepadatan penduduk dan tradisi akademik yang kuat di wilayah Northeastern US.


Gambar 2: Founded Year vs. Enrollment (Skala Log) berdasarkan Control



Gambar 2. Scatter plot tahun pendirian versus enrollment dengan skala logaritmik, dibedakan per jenis kepemilikan.

Insight: Institusi publik (biru) secara umum memiliki enrollment lebih tinggi dibandingkan institusi swasta (merah), terlihat dari posisinya yang lebih dominan di bagian atas grafik. Konsentrasi titik data terbesar terjadi pada era 1880–1970, mencerminkan ekspansi besar-besaran sistem pendidikan tinggi AS pasca-Perang Dunia II. Beberapa institusi yang didirikan sebelum 1700 (era kolonial) sudah memiliki enrollment besar, menunjukkan reputasi dan daya tarik yang bertahan lama.


Gambar 3: Matriks Korelasi — Enrollment, Founded, Control (One-Hot)



Gambar 3. Matriks korelasi Pearson antar variabel numerik dan variabel Control yang diencode secara one-hot.

Insight: Korelasi antara Control_Public dan Enrollment bernilai +0,21, mengonfirmasi bahwa institusi publik cenderung memiliki lebih banyak mahasiswa. Sebaliknya, Control_Private berkorelasi -0,21 dengan Enrollment. Founded berkorelasi lemah negatif (-0,09) dengan Enrollment, mengindikasikan bahwa institusi yang lebih tua tidak selalu lebih besar. Secara keseluruhan, korelasi antar variabel relatif rendah, menandakan bahwa faktor lain (lokasi, reputasi, program studi) lebih berpengaruh terhadap ukuran enrollment.

Gambar 4: Enrollment per Control (Skala Log)



Gambar 4. Boxplot enrollment berdasarkan jenis kepemilikan dengan skala logaritmik.

Insight: Institusi Public memiliki median enrollment tertinggi (~5.000 mahasiswa), jauh di atas institusi Private (~1.100) maupun Other (~2.000). Kotak IQR institusi publik juga lebih sempit secara proporsional (dalam skala log), menandakan distribusi yang lebih seragam. Institusi Private memiliki variasi sangat besar, dari puluhan hingga ratusan ribu mahasiswa, tercermin dari banyaknya outlier di atas whisker. Ini menunjukkan bahwa "private" mencakup spektrum sangat luas, mulai dari sekolah kecil hingga universitas riset besar.

5. Kesimpulan

Analisis EDA pada dataset 1.682 perguruan tinggi AS mengungkap beberapa temuan utama: (1) institusi swasta mendominasi secara numerik namun institusi publik unggul dalam ukuran enrolment. (2) sebagian besar perguruan tinggi aktif didirikan antara 1880–1970. (3) Pennsylvania adalah negara bagian dengan konsentrasi institusi tertinggi. (4) distribusi enrollment bersifat sangat right-skewed dengan outlier signifikan. Temuan ini memberikan landasan yang baik untuk analisis lanjutan, misalnya pemodelan prediktif enrollment atau analisis geografis distribusi akses pendidikan tinggi.